DATA SCIENCE 1 · 2026–2027

# Van bestand tot nette tabel

Syllabus voor labo 3 – *Dataverwerking I*

| | |
|---|---|
| Lesgever | dr. Maarten Slembrouck |
| Sessie | labo 3 – *Dataverwerking I* |
| Lesmateriaal | `https://github.com/PACE-Ghent/Data-Science-1-2026` |

## 1 Overzicht

Tijdens labo 3, 4 en 5 ben jij de nieuwe data-analist van een (fictieve) jeugdclub voor voetbal en atletiek. De hoofdtrainer bezorgt je drie exportbestanden uit de systemen van de club. Die zijn bewust rommelig, zoals echte exports: inconsistente labels, sprinttijden in milliseconden, ontbrekende waarden, een atleet die twee keer voorkomt en een kolom met een komma als decimaalteken.

Elke sessie bouwt verder op de vorige:

**Labo 3** **Van bestand tot nette tabel.** Inladen, verkennen, filteren, kolommen toevoegen en opkuisen tot je de data kunt vertrouwen.

**Labo 4** **Combineren, samenvatten, herschikken.** Groepen samenvatten, tabellen koppelen, wisselen tussen een brede en een lange vorm, en werken met een hartslagreeks per seconde.

**Labo 5** **Vertel het verhaal met plotly.** De juiste grafiek kiezen voor een vraag, eerlijke grafieken maken met `plotly.express` en ze combineren tot een klein interactief dashboard.

## 2 Leerdoelen

Na labo 3 kun je:

**LD1** een CSV-bestand inladen met `pandas` en de structuur, de datatypes en de ontbrekende waarden beschrijven;

**LD2** rijen en kolommen selecteren en filteren met logische voorwaarden, en het resultaat sorteren;

**LD3** nieuwe kolommen afleiden (leeftijd, snelheid, BMI) en tekst omzetten naar getallen en datums;

**LD4** een dataset opkuisen en elke keuze verantwoorden: inconsistente tekstlabels, verkeerde eenheden, ontbrekende waarden en dubbels.

## 3 Voorkennis

Labo 1 en 2 (*Introductie Python I en II*): variabelen en datatypes, operatoren, `if`/`elif`/`else`, functies, stringmethodes, lijsten, dictionaries, lussen en een CSV-bestand inlezen met de module `csv`. Labo 2 eindigt met een samenvatting van `athletes.csv` in gewone Python; in labo 3 zie je hoe `pandas` hetzelfde doet in enkele regels.

## 4 Software en lesmateriaal

Elk labo is een **marimo-notebook** in de map `labs/` van de cursusrepository. Je kunt het op twee manieren openen:

- **Online:** surf naar `https://marimo.app`, kies *New* → *Open from URL…* en plak de raw-URL van het notebook op GitHub. De data wordt dan van GitHub gelezen, dus je hoeft niets te installeren.
- **Lokaal:** installeer de pakketten uit `requirements.txt` en open het notebook met marimo. De data wordt dan uit de map `data/` gelezen.

Drie dingen die je moet weten over marimo:

- Notebooks zijn **reactief**: als je een cel aanpast, worden alle cellen die ervan afhangen opnieuw uitgevoerd, in de volgorde van hun afhankelijkheden.
- **Twee cellen kunnen niet dezelfde variabele definiëren.** Geef elke stap een eigen, duidelijke naam (`tests_raw`, `tests_clean`, …) of zet een reeks stappen samen in één cel.
- Elke oefening bevat een placeholder `....` Een verborgen cel eronder controleert je antwoord: die kleurt **groen** als het juist is, en geeft anders een algemene hint over wat nog niet klopt, zonder het antwoord te verklappen.

## 5 De dataset

| Bestand | Omvang | Inhoud en gekende problemen |
|---|---|---|
| `athletes.csv` | 43 rijen, 7 kolommen | ID, naam, geboortedatum, geslacht, positie, lengte, gewicht. 13 schrijfwijzen voor 4 posities, gewicht als tekst met een decimale komma (`"57,5"`), één atleet twee keer ingevoerd met twee ID's, enkele ontbrekende waarden. |
| `tests.csv` | 114 rijen, 8 kolommen | Sprint over 10 m en 30 m, spronghoogte (countermovement jump) en Yo-Yo-niveau, op 3 testmomenten. Sommige sprinttijden staan in milliseconden; enkele ontbrekende waarden. |
| `hr_session.csv` | 12 000 rijen, 5 kolommen | Hartslag en snelheid per seconde van 5 atleten tijdens één training van 40 minuten. |

## 6 Planning

**Doel:** een dataset inladen en verkennen, rijen en kolommen selecteren en filteren, nieuwe kolommen toevoegen en de data opkuisen.

| Tijd | Blok | Wat je oefent |
|---|---|---|
| 13:00–13:20 | Opwarmer: waarom niet gewoon Excel? | De ruwe tekst van een CSV-bestand bekijken en zien wat een tabelbibliotheek toevoegt. |
| 13:20–14:00 | Inladen en verkennen | `read_csv`, `.head()`, `.shape`, `.dtypes`, `.info()`, `.describe()`, `mo.ui.table`. |
| 14:00–14:50 | Selecteren en filteren | Kolommen selecteren, `.loc` met logische voorwaarden, voorwaarden combineren, `sort_values`. |
| 14:50–15:05 | Pauze | |
| 15:05–15:50 | Nieuwe kolommen | Tekst naar getal, leeftijd uit een geboortedatum, snelheid uit een sprinttijd, BMI. |
| 15:50–17:00 | Opkuisen | Ontbrekende waarden (`dropna` of `fillna`), tekstlabels, eenheden, dubbels, één volledige opkuis-pipeline. |
| 17:00–17:30 | Uitdaging | De 5 snelste atleten per positie. Exit ticket. |

**Oefeningen:** (1) `tests.csv` inladen; (2) aanvallers jonger dan 16; (3) verdachte sprinttijden; (4) BMI; (5) leeftijd in jaren; (6) de posities opkuisen; (7) de eenheden van de sprinttijden corrigeren; (8) de dubbele atleet verwijderen; **uitdaging:** de 5 snelsten per positie.

## 7 Werkwijze

- Elk blok start met een korte demo in het notebook, gevolgd door oefeningen die je in het notebook zelf oplost.
- Gebruik de automatische controles als feedback, niet als doel: als een controle groen kleurt, zorg dan dat je kunt uitleggen *waarom* je code werkt.
- Het labo eindigt met een exit ticket: één techniek die je opnieuw zult gebruiken en één ding dat nog niet duidelijk is. Breng de onduidelijke punten mee naar labo 4.

## 8 Voorbereiding

- Controleer vóór de sessie dat je het notebook kunt openen, lokaal of op marimo.app.
- Herhaal lijsten, dictionaries en functies uit labo 2: pandas gebruikt ze voortdurend.
- Lees de cursustekst bij labo 3 naast het notebook.