DATA SCIENCE 1 · 2026–2027

Van bestand tot nette tabel

Syllabus voor labo 3 – *Dataverwerking I*

Lesgever	dr. Maarten Slembrouck
Sessie	labo 3 – *Dataverwerking I*

1 Overzicht

Tijdens labo 3, 4 en 5 ben jij de nieuwe data-analist van een (fictieve) jeugdclub voor voetbal en atletiek. De hoofdtrainer bezorgt je drie exportbestanden uit de systemen van de club. Die zijn bewust rommelig, zoals echte exports: inconsistente labels, sprinttijden in milliseconden, ontbrekende waarden, een atleet die twee keer voorkomt en een kolom met een komma als decimaalteken.

Elke sessie bouwt verder op de vorige:

Labo 3 **Van bestand tot nette tabel.** Inladen, verkennen, filteren, kolommen toevoegen en opkuisen tot je de data kunt vertrouwen.

Labo 4 **Combineren, samenvatten, herschikken.** Groepen samenvatten, tabellen koppelen, wisselen tussen een brede en een lange vorm, en werken met een hartslagreeks per seconde.

Labo 5 **Vertel het verhaal met plotly.** De juiste grafiek kiezen voor een vraag, eerlijke grafieken maken met `plotly.express` en ze combineren tot een klein interactief dashboard.

2 Leerdoelen

Na labo 3 kun je:

LD1 een CSV-bestand inladen met `pandas` en de structuur, de datatypes en de ontbrekende waarden beschrijven;

LD2 rijen en kolommen selecteren en filteren met logische voorwaarden, en het resultaat sorteren;

LD3 nieuwe kolommen afleiden (leeftijd, snelheid, BMI) en tekst omzetten naar getallen en datums;

LD4 een dataset opkuisen en elke keuze verantwoorden: inconsistente tekstlabels, verkeerde eenheden, ontbrekende waarden en dubbels.

3 Voorkennis

Labo 1 en 2 (*Introductie Python I en II*): variabelen en datatypes, operatoren, `if`/`elif`/`else`, functies, stringmethodes, lijsten, dictionaries, lussen en een CSV-bestand inlezen met de module `csv`. Labo 2 eindigt met een samenvatting van `athletes.csv` in gewone Python; in labo 3 zie je hoe `pandas` hetzelfde doet in enkele regels.

4 Software en lesmateriaal

Elk labo is een **marimo-notebook** in de map `labs/` van de cursusrepository. Je kunt het op twee manieren openen:

- **Online:** surf naar `https://marimo.app`, kies *New* → *Open from URL...* en plak de link naar het notebook die je van de lesgever krijgt. De data wordt dan online gelezen, dus je hoeft niets te installeren.
- **Lokaal:** installeer `uv` en Python 3.12 volgens de handleiding *Python installeren* (of de slides). Ga daarna in een terminal naar de map van de cursus en open een labo met:
  `uv run marimo edit labs/lab3_data_processing_I.py`
  uv installeert de eerste keer zelf de nodige packages; de data wordt uit de map `data/` gelezen.

Drie dingen die je moet weten over marimo:

- Notebooks zijn **reactief**: als je een cel aanpast, worden alle cellen die ervan afhangen opnieuw uitgevoerd, in de volgorde van hun afhankelijkheden.
- **Twee cellen kunnen niet dezelfde variabele definiëren.** Geef elke stap een eigen, duidelijke naam (`tests_raw`, `tests_clean`, ...) of zet een reeks stappen samen in één cel.
- Elke oefening bevat een placeholder `...`. Een verborgen cel eronder controleert je antwoord: die kleurt **groen** als het juist is, en geeft anders een algemene hint over wat nog niet klopt, zonder het antwoord te verklappen.

5 De dataset

Bestand	Omvang	Inhoud en gekende problemen
`athletes.csv`	43 rijen, 7 kolommen	ID, naam, geboortedatum, geslacht, positie, lengte, gewicht. 13 schrijfwijzen voor 4 posities, gewicht als tekst met een decimale komma (`"57,5"`), één atleet twee keer ingevoerd met twee ID's, enkele ontbrekende waarden.
`tests.csv`	114 rijen, 8 kolommen	Sprint over 10 m en 30 m, spronghoogte (countermovement jump) en Yo-Yo-niveau, op 3 testmomenten. Sommige sprinttijden staan in milliseconden; enkele ontbrekende waarden.
`hr_session.csv`	12 000 rijen, 5 kolommen	Hartslag en snelheid per seconde van 5 atleten tijdens één training van 40 minuten.

6 Planning

Doel: een dataset inladen en verkennen, rijen en kolommen selecteren en filteren, nieuwe kolommen toevoegen en de data opkuisen.

Tijd	Blok	Wat je oefent
13:00–13:20	Opwarmer: waarom niet gewoon Excel?	De ruwe tekst van een CSV-bestand bekijken en zien wat een tabelbibliotheek toevoegt.
13:20–14:00	Inladen en verkennen	`read_csv`, `.head()`, `.shape`, `.dtypes`, `.info()`, `.describe()`, `mo.ui.table`.
14:00–14:50	Selecteren en filteren	Kolommen selecteren, `.loc` met logische voorwaarden, voorwaarden combineren, `sort_values`.
14:50–15:05	Pauze	
15:05–15:50	Nieuwe kolommen	Tekst naar getal, leeftijd uit een geboortedatum, snelheid uit een sprinttijd, BMI.
15:50–17:00	Opkuisen	Ontbrekende waarden (`dropna` of `fillna`), tekstlabels, eenheden, dubbels, één volledige opkuis-pipeline.
17:00–17:30	Uitdaging	De 5 snelste atleten per positie. Exit ticket.

Oefeningen: (1) `tests.csv` inladen; (2) aanvallers jonger dan 16; (3) verdachte sprinttijden; (4) BMI; (5) leeftijd in jaren; (6) de posities opkuisen; (7) de eenheden van de sprinttijden corrigeren; (8) de dubbele atleet verwijderen; **uitdaging:** de 5 snelsten per positie.

7 Werkwijze

- Elk blok start met een korte demo in het notebook, gevolgd door oefeningen die je in het notebook zelf oplost.
- Gebruik de automatische controles als feedback, niet als doel: als een controle groen kleurt, zorg dan dat je kunt uitleggen *waarom* je code werkt.
- Het labo eindigt met een exit ticket: één techniek die je opnieuw zult gebruiken en één ding dat nog niet duidelijk is. Breng de onduidelijke punten mee naar labo 4.

8 Voorbereiding

- Controleer vóór de sessie dat je het notebook kunt openen, lokaal of op marimo.app.
- Herhaal lijsten, dictionaries en functies uit labo 2: pandas gebruikt ze voortdurend.
- Lees de cursustekst bij labo 3 naast het notebook.