DATA SCIENCE 1 · 2026–2027

Combineren, samenvatten, herschikken

Syllabus voor labo 4 – *Dataverwerking II*

Lesgever	dr. Maarten Slembrouck
Sessie	labo 4 – *Dataverwerking II*
Lesmateriaal	`https://github.com/PACE-Ghent/Data-Science-1-2026`

1 Overzicht

Tijdens labo 3, 4 en 5 ben jij de nieuwe data-analist van een (fictieve) jeugdclub voor voetbal en atletiek. De hoofdtrainer bezorgt je drie exportbestanden uit de systemen van de club. Die zijn bewust rommelig, zoals echte exports: inconsistente labels, sprinttijden in milliseconden, ontbrekende waarden, een atleet die twee keer voorkomt en een kolom met een komma als decimaalteken.

Elke sessie bouwt verder op de vorige:

Labo 3 **Van bestand tot nette tabel.** Inladen, verkennen, filteren, kolommen toevoegen en opkuisen tot je de data kunt vertrouwen.

Labo 4 **Combineren, samenvatten, herschikken.** Groepen samenvatten, tabellen koppelen, wisselen tussen een brede en een lange vorm, en werken met een hartslagreeks per seconde.

Labo 5 **Vertel het verhaal met plotly.** De juiste grafiek kiezen voor een vraag, eerlijke grafieken maken met `plotly.express` en ze combineren tot een klein interactief dashboard.

2 Leerdoelen

Na labo 4 kun je:

LD1 data per groep samenvatten met `groupby` en `agg`, en tabellen koppelen met `merge` zonder dubbel te tellen;

LD2 data herschikken tussen een lange en een brede vorm met `melt` en `pivot_table`;

LD3 eenvoudige kenmerken van een tijdreeks berekenen: hartslagzones, voortschrijdende gemiddelden en hersampling.

3 Voorkennis

Labo 3 (*Dataverwerking I*): een CSV-bestand inladen met `pandas`, rijen en kolommen selecteren en filteren, nieuwe kolommen berekenen en de data opkuisen. Labo 4 start met de opkuis-pipeline van labo 3, in compacte vorm.

4 Software en lesmateriaal

Elk labo is een **marimo-notebook** in de map `labs/` van de cursusrepository. Je kunt het op twee manieren openen:

- **Online:** surf naar `https://marimo.app`, kies *New* → *Open from URL…* en plak de raw-URL van het notebook op GitHub. De data wordt dan van GitHub gelezen, dus je hoeft niets te installeren.

- **Lokaal:** installeer `uv` en Python 3.12 volgens de handleiding *Python installeren* (of de slides). Ga daarna in een terminal naar de map van de cursus en open een labo met:
  `uv run marimo edit labs/lab3_data_processing_I.py`
  uv installeert de eerste keer zelf de nodige packages; de data wordt uit de map `data/` gelezen.

Drie dingen die je moet weten over marimo:

- Notebooks zijn **reactief**: als je een cel aanpast, worden alle cellen die ervan afhangen opnieuw uitgevoerd, in de volgorde van hun afhankelijkheden.
- **Twee cellen kunnen niet dezelfde variabele definiëren.** Geef elke stap een eigen, duidelijke naam (`tests_raw`, `tests_clean`, ...) of zet een reeks stappen samen in één cel.
- Elke oefening bevat een placeholder `...`. Een verborgen cel eronder controleert je antwoord: die kleurt **groen** als het juist is, en geeft anders een algemene hint over wat nog niet klopt, zonder het antwoord te verklappen.

5 De dataset

Bestand	Omvang	Inhoud en gekende problemen
`athletes.csv`	43 rijen, 7 kolommen	ID, naam, geboortedatum, geslacht, positie, lengte, gewicht. 13 schrijfwijzen voor 4 posities, gewicht als tekst met een decimale komma (`"57,5"`), één atleet twee keer ingevoerd met twee ID's, enkele ontbrekende waarden.
`tests.csv`	114 rijen, 8 kolommen	Sprint over 10 m en 30 m, spronghoogte (countermovement jump) en Yo-Yo-niveau, op 3 testmomenten. Sommige sprinttijden staan in milliseconden; enkele ontbrekende waarden.
`hr_session.csv`	12 000 rijen, 5 kolommen	Hartslag en snelheid per seconde van 5 atleten tijdens één training van 40 minuten.

6 Planning

Doel: data aggregeren met `groupby`, tabellen koppelen met `merge`, herschikken met `melt` en `pivot`, en eenvoudige kenmerken van een tijdreeks berekenen.

Tijd	Blok	Wat je oefent
13:00–13:15	Herhaling: een kapotte cel herstellen	Een kleine opkuis-pipeline met twee fouten repareren.
13:15–14:10	`groupby` + `agg`	Statistieken per groep, leeftijdscategorieën met `pd.cut`, meerdere benoemde aggregaties tegelijk.
14:10–14:55	`merge`	Inner en left joins; waarom een dubbele atleet twee keer meetelt, en waarom je dubbels verwijdert vóór het koppelen.
14:55–15:10	Pauze	
15:10–15:50	`melt` en `pivot`	Lange en brede vorm; vooruitgang tussen twee testmomenten.
15:50–16:50	Tijdreeksen	Hartslagzones als % van HR_{max} (220 − leeftijd), tijd per zone, `rolling`, `resample`.
16:50–17:30	Minicase per twee	Een trainingsrapport: één rij per atleet.

Oefeningen: (0) herhaling: de kapotte cel herstellen; (1) groeperen per geslacht en leeftijdscategorie; (2) wat heeft het verwijderen van de dubbels gekost?; (3) vooruitgang in spronghoogte; (4) minuten in zone 4–5 per atleet; **minicase:** trainingsrapport met de minuten in zone 4–5, de maximale snelheid en de afgelegde afstand per atleet.

7 Werkwijze

- Elk blok start met een korte demo in het notebook, gevolgd door oefeningen die je in het notebook zelf oplost.
- Gebruik de automatische controles als feedback, niet als doel: als een controle groen kleurt, zorg dan dat je kunt uitleggen *waarom* je code werkt.
- De minicase op het einde maak je per twee.

8 Voorbereiding

- Controleer vóór de sessie dat je het notebook kunt openen, lokaal of op marimo.app.
- Zorg dat je elke stap van de opkuis-pipeline op het einde van labo 3 kunt uitleggen, want labo 4 vertrekt daarvan.
- Lees de cursustekst bij labo 4 naast het notebook.