DATA SCIENCE 1 · 2026–2027

Vertel het verhaal met plotly

Syllabus voor labo 5 – *Datavisualisatie I*

Lesgever	dr. Maarten Slembrouck
Sessie	labo 5 – *Datavisualisatie I*
Lesmateriaal	`https://github.com/PACE-Ghent/Data-Science-1-2026`

1 Overzicht

Tijdens labo 3, 4 en 5 ben jij de nieuwe data-analist van een (fictieve) jeugdclub voor voetbal en atletiek. De hoofdtrainer bezorgt je drie exportbestanden uit de systemen van de club. Die zijn bewust rommelig, zoals echte exports: inconsistente labels, sprinttijden in milliseconden, ontbrekende waarden, een atleet die twee keer voorkomt en een kolom met een komma als decimaalteken.

Elke sessie bouwt verder op de vorige:

Labo 3 **Van bestand tot nette tabel.** Inladen, verkennen, filteren, kolommen toevoegen en opkuisen tot je de data kunt vertrouwen.

Labo 4 **Combineren, samenvatten, herschikken.** Groepen samenvatten, tabellen koppelen, wisselen tussen een brede en een lange vorm, en werken met een hartslagreeks per seconde.

Labo 5 **Vertel het verhaal met plotly.** De juiste grafiek kiezen voor een vraag, eerlijke grafieken maken met `plotly.express` en ze combineren tot een klein interactief dashboard.

2 Leerdoelen

Na labo 5 kun je:

LD1 een grafiektype kiezen dat bij de vraag past, en misleidende grafieken herkennen, zoals een afgeknotte as;

LD2 met `plotly.express` histogrammen, boxplots, spreidingsdiagrammen en lijngrafieken maken, met kleur, facetten en grootte voor extra dimensies;

LD3 grafieken interactief maken met UI-elementen van marimo en ze combineren tot een dashboard.

3 Voorkennis

Labo 3 en 4 (*Dataverwerking I en II*): data inladen, filteren en opkuisen met `pandas`, groeperen met `groupby`, tabellen koppelen met `merge` en het verschil tussen een lange en een brede vorm. Labo 5 start met de volledige opkuis van labo 3 en 4 in één cel.

4 Software en lesmateriaal

Elk labo is een **marimo-notebook** in de map `labs/` van de cursusrepository. Je kunt het op twee manieren openen:

- **Online:** surf naar `https://marimo.app`, kies *New* → *Open from URL…* en plak de raw-URL van het notebook op GitHub. De data wordt dan van GitHub gelezen, dus je hoeft niets

te installeren.

- **Lokaal:** installeer de pakketten uit `requirements.txt` en open het notebook met marimo. De data wordt dan uit de map `data/` gelezen.

Drie dingen die je moet weten over marimo:

- Notebooks zijn **reactief**: als je een cel aanpast, worden alle cellen die ervan afhangen opnieuw uitgevoerd, in de volgorde van hun afhankelijkheden.
- **Twee cellen kunnen niet dezelfde variabele definiëren.** Geef elke stap een eigen, duidelijke naam (`tests_raw`, `tests_clean`, ...) of zet een reeks stappen samen in één cel.
- Elke oefening bevat een placeholder `...`. Een verborgen cel eronder controleert je antwoord: die kleurt **groen** als het juist is, en geeft anders een algemene hint over wat nog niet klopt, zonder het antwoord te verklappen.

5 De dataset

Bestand	Omvang	Inhoud en gekende problemen
`athletes.csv`	43 rijen, 7 kolommen	ID, naam, geboortedatum, geslacht, positie, lengte, gewicht. 13 schrijfwijzen voor 4 posities, gewicht als tekst met een decimale komma (`"57,5"`), één atleet twee keer ingevoerd met twee ID's, enkele ontbrekende waarden.
`tests.csv`	114 rijen, 8 kolommen	Sprint over 10 m en 30 m, spronghoogte (countermovement jump) en Yo-Yo-niveau, op 3 testmomenten. Sommige sprinttijden staan in milliseconden; enkele ontbrekende waarden.
`hr_session.csv`	12 000 rijen, 5 kolommen	Hartslag en snelheid per seconde van 5 atleten tijdens één training van 40 minuten.

6 Planning

Doel: een grafiektype kiezen voor een gegeven vraag, de standaardgrafieken van `plotly.express` maken, extra dimensies toevoegen met kleur, facetten en grootte, en eenvoudige interactiviteit inbouwen.

Tijd	Blok	Wat je oefent
13:00–13:30	Principes	De juiste grafiek voor de vraag (verdeling, vergelijking, verband, evolutie); kritiek op een misleidende grafiek.
13:30–14:30	Basis van `plotly.express`	Histogram, boxplot, spreidingsdiagram en lijngrafiek, met titels, aslabels en hover-informatie.
14:30–15:15	Meer dimensies	`color`, `facet_col` en `size`; één vaste kleur per positie.
15:15–15:30	Pauze	
15:30–16:15	Hartslag als tijdreeks	Zonebanden met `add_hrect`, en waarom we geen tweede y-as gebruiken.
16:15–16:45	Interactiviteit	`mo.ui.dropdown`, `mo.ui.range_slider`, optioneel selecties met `mo.ui.plotly`.
16:45–17:30	Minidashboard	3 grafieken en 1 keuzemenu waarop minstens één grafiek reageert.

Oefeningen: (1) een histogram van het gewicht; (2) Yo-Yo-niveau per positie, met facetten per geslacht; (3) snelheid doorheen de tijd voor één atleet; **opdracht:** het minidashboard.

7 Werkwijze

- Elk blok start met een korte demo in het notebook, gevolgd door oefeningen die je in het notebook zelf oplost.
- Gebruik de automatische controles als feedback, niet als doel: als een controle groen kleurt, zorg dan dat je kunt uitleggen *waarom* je code werkt.
- Het minidashboard bouw je met alles uit dit labo: het doel is combineren, niet nieuwe grafiektypes leren.

8 Evaluatie

- **Minidashboard:** drie grafieken en één interactief keuzemenu, gemaakt met de data van de club. Het kan dienen als je inzending voor deze module en bereidt de casepresentaties en het Project Lab van volgend semester voor.

9 Voorbereiding

- Controleer vóór de sessie dat je het notebook kunt openen, lokaal of op marimo.app.
- Herhaal `groupby`, `merge` en de lange vorm uit labo 4. Grafieken met plotly express vertrekken van data in de lange vorm.
- Lees de cursustekst bij labo 5 naast het notebook.