DATA SCIENCE 1 · 2026–2027

Van rommelige export tot coachdashboard

Syllabus voor labo 3, 4 en 5

Lesgever	dr. Maarten Slembrouck
Sessie	labo 3, 4 en 5

1 Overzicht

Tijdens labo 3, 4 en 5 ben jij de nieuwe data-analist van een (fictieve) jeugdclub voor voetbal en atletiek. De hoofdtrainer bezorgt je drie exportbestanden uit de systemen van de club. Die zijn bewust rommelig, zoals echte exports: inconsistente labels, sprinttijden in milliseconden, ontbrekende waarden, een atleet die twee keer voorkomt en een kolom met een komma als decimaalteken.

Elke sessie bouwt verder op de vorige:

Labo 3 **Van bestand tot nette tabel.** Inladen, verkennen, filteren, kolommen toevoegen en opkuisen tot je de data kunt vertrouwen.

Labo 4 **Combineren, samenvatten, herschikken.** Groepen samenvatten, tabellen koppelen, wisselen tussen een brede en een lange vorm, en werken met een hartslagreeks per seconde.

Labo 5 **Vertel het verhaal met plotly.** De juiste grafiek kiezen voor een vraag, eerlijke grafieken maken met `plotly.express` en ze combineren tot een klein interactief dashboard.

2 Leerdoelen

Na deze drie sessies kun je:

LD1 een CSV-bestand inladen met `pandas` en de structuur, de datatypes en de ontbrekende waarden beschrijven;

LD2 rijen en kolommen selecteren en filteren met logische voorwaarden, en het resultaat sorteren;

LD3 nieuwe kolommen afleiden (leeftijd, snelheid, BMI) en tekst omzetten naar getallen en datums;

LD4 een dataset opkuisen en elke keuze verantwoorden: inconsistente tekstlabels, verkeerde eenheden, ontbrekende waarden en dubbels;

LD5 data per groep samenvatten met `groupby` en `agg`, en tabellen koppelen met `merge` zonder dubbel te tellen;

LD6 data herschikken tussen een lange en een brede vorm met `melt` en `pivot_table`;

LD7 eenvoudige kenmerken van een tijdreeks berekenen: hartslagzones, voortschrijdende gemiddelden en hersampling;

LD8 een grafiektype kiezen dat bij de vraag past, en misleidende grafieken herkennen, zoals een afgeknotte as;

LD9 met `plotly.express` histogrammen, boxplots, spreidingsdiagrammen en lijngrafieken maken, met kleur, facetten en grootte voor extra dimensies;

LD10 grafieken interactief maken met UI-elementen van marimo en ze combineren tot een dashboard.

3 Voorkennis

Labo 1 en 2 (*Introductie Python I en II*): variabelen en datatypes, operatoren, `if`/`elif`/`else`, functies, stringmethodes, lijsten, dictionaries, lussen en een CSV-bestand inlezen met de module `csv`. Labo 2 eindigt met een samenvatting van `athletes.csv` in gewone Python; in labo 3 zie je hoe `pandas` hetzelfde doet in enkele regels.

4 Software en lesmateriaal

Elk labo is een **marimo-notebook** in de map `labs/` van de cursusrepository. Je kunt het op twee manieren openen:

- **Online:** surf naar `https://marimo.app`, kies *New* → *Open from URL…* en plak de link naar het notebook die je van de lesgever krijgt. De data wordt dan online gelezen, dus je hoeft niets te installeren.
- **Lokaal:** installeer `uv` en Python 3.12 volgens de handleiding *Python installeren* (of de slides). Ga daarna in een terminal naar de map van de cursus en open een labo met:
  `uv run marimo edit labs/lab3_data_processing_I.py`
  uv installeert de eerste keer zelf de nodige packages; de data wordt uit de map `data/` gelezen.

Drie dingen die je moet weten over marimo:

- Notebooks zijn **reactief**: als je een cel aanpast, worden alle cellen die ervan afhangen opnieuw uitgevoerd, in de volgorde van hun afhankelijkheden.
- **Twee cellen kunnen niet dezelfde variabele definiëren.** Geef elke stap een eigen, duidelijke naam (`tests_raw`, `tests_clean`, …) of zet een reeks stappen samen in één cel.
- Elke oefening bevat een placeholder `....` Een verborgen cel eronder controleert je antwoord: die kleurt **groen** als het juist is, en geeft anders een algemene hint over wat nog niet klopt, zonder het antwoord te verklappen.

5 De dataset

Bestand	Omvang	Inhoud en gekende problemen
`athletes.csv`	43 rijen, 7 kolommen	ID, naam, geboortedatum, geslacht, positie, lengte, gewicht. 13 schrijfwijzen voor 4 posities, gewicht als tekst met een decimale komma (`"57,5"`), één atleet twee keer ingevoerd met twee ID's, enkele ontbrekende waarden.
`tests.csv`	114 rijen, 8 kolommen	Sprint over 10 m en 30 m, sprongHoogte (countermovement jump) en Yo-Yo-niveau, op 3 testmomenten. Sommige sprinttijden staan in milliseconden; enkele ontbrekende waarden.
`hr_session.csv`	12 000 rijen, 5 kolommen	Hartslag en snelheid per seconde van 5 atleten tijdens één training van 40 minuten.

6 Planning per sessie

6.1 Labo 3 – Dataverwerking I: van bestand tot nette tabel

Doel: een dataset inladen en verkennen, rijen en kolommen selecteren en filteren, nieuwe kolommen toevoegen en de data opkuisen.

Tijd	Blok	Wat je oefent
13:00–13:20	Opwarmer: waarom niet gewoon Excel?	De ruwe tekst van een CSV-bestand bekijken en zien wat een tabelbibliotheek toevoegt.
13:20–14:00	Inladen en verkennen	`read_csv`, `.head()`, `.shape`, `.dtypes`, `.info()`, `.describe()`, `mo.ui.table`.
14:00–14:50	Selecteren en filteren	Kolommen selecteren, `.loc` met logische voorwaarden, voorwaarden combineren, `sort_values`.
14:50–15:05	Pauze	
15:05–15:50	Nieuwe kolommen	Tekst naar getal, leeftijd uit een geboortedatum, snelheid uit een sprinttijd, BMI.
15:50–17:00	Opkuisen	Ontbrekende waarden (`dropna` of `fillna`), tekstlabels, eenheden, dubbels, één volledige opkuis-pipeline.
17:00–17:30	Uitdaging	De 5 snelste atleten per positie. Exit ticket.

Oefeningen: (1) `tests.csv` inladen; (2) aanvallers jonger dan 16; (3) verdachte sprinttijden; (4) BMI; (5) leeftijd in jaren; (6) de posities opkuisen; (7) de eenheden van de sprinttijden corrigeren; (8) de dubbele atleet verwijderen; **uitdaging:** de 5 snelsten per positie.

6.2 Labo 4 – Dataverwerking II: combineren, samenvatten, herschikken

Doel: data aggregeren met `groupby`, tabellen koppelen met `merge`, herschikken met `melt` en `pivot`, en eenvoudige kenmerken van een tijdreeks berekenen.

Tijd	Blok	Wat je oefent
13:00–13:15	Herhaling: een kapotte cel herstellen	Een kleine opkuis-pipeline met twee fouten repareren.
13:15–14:10	`groupby` + `agg`	Statistieken per groep, leeftijdscategorieën met `pd.cut`, meerdere benoemde aggregaties tegelijk.
14:10–14:55	`merge`	Inner en left joins; waarom een dubbele atleet twee keer meetelt, en waarom je dubbels verwijdert vóór het koppelen.
14:55–15:10	Pauze	
15:10–15:50	`melt` en `pivot`	Lange en brede vorm; vooruitgang tussen twee testmomenten.
15:50–16:50	Tijdreeksen	Hartslagzones als % van HR_{max} (220 − leeftijd), tijd per zone, `rolling`, `resample`.
16:50–17:30	Minicase per twee	Een trainingsrapport: één rij per atleet.

Oefeningen: (0) herhaling: de kapotte cel herstellen; (1) groeperen per geslacht en leeftijdscategorie; (2) wat heeft het verwijderen van de dubbels gekost?; (3) vooruitgang in spronghoogte; (4) minuten in zone 4–5 per atleet; **minicase:** trainingsrapport met de minuten in zone 4–5, de maximale snelheid en de afgelegde afstand per atleet.

6.3 Labo 5 – Datavisualisatie I: vertel het verhaal met plotly

Doel: een grafiektype kiezen voor een gegeven vraag, de standaardgrafieken van `plotly.express` maken, extra dimensies toevoegen met kleur, facetten en grootte, en eenvoudige interactiviteit inbouwen.

Tijd	Blok	Wat je oefent
13:00–13:30	Principes	De juiste grafiek voor de vraag (verdeling, vergelijking, verband, evolutie); kritiek op een misleidende grafiek.
13:30–14:30	Basis van `plotly.express`	Histogram, boxplot, spreidingsdiagram en lijngrafiek, met titels, aslabels en hover-informatie.
14:30–15:15	Meer dimensies	`color`, `facet_col` en `size`; één vaste kleur per positie.
15:15–15:30	Pauze	
15:30–16:15	Hartslag als tijdreeks	Zonebanden met `add_hrect`, en waarom we geen tweede y-as gebruiken.
16:15–16:45	Interactiviteit	`mo.ui.dropdown`, `mo.ui.range_slider`, optioneel selecties met `mo.ui.plotly`.
16:45–17:30	Minidashboard	3 grafieken en 1 keuzemenu waarop minstens één grafiek reageert.

Oefeningen: (1) een histogram van het gewicht; (2) Yo-Yo-niveau per positie, met facetten per geslacht; (3) snelheid doorheen de tijd voor één atleet; **opdracht:** het minidashboard.

7 Werkwijze

- Elk blok start met een korte demo in het notebook, gevolgd door oefeningen die je in het notebook zelf oplost.
- Gebruik de automatische controles als feedback, niet als doel: als een controle groen kleurt, zorg dan dat je kunt uitleggen *waarom* je code werkt.
- De minicase van labo 4 maak je per twee.
- Labo 3 eindigt met een exit ticket: één techniek die je opnieuw zult gebruiken en één ding dat nog niet duidelijk is. Breng de onduidelijke punten mee naar de volgende sessie.

8 Evaluatie

- **Minidashboard (labo 5):** drie grafieken en één interactief keuzemenu, gemaakt met de data van de club. Het kan dienen als je inzending voor deze module en bereidt de casepresentaties en het Project Lab van volgend semester voor.

9 Voorbereiding per sessie

- Controleer vóór elke sessie dat je het notebook kunt openen, lokaal of op marimo.app.
- Vóór labo 3: herhaal lijsten, dictionaries en functies uit labo 2.
- Vóór labo 4: zorg dat je elke stap van de opkuis-pipeline op het einde van labo 3 kunt uitleggen, want labo 4 vertrekt daarvan.
- Vóór labo 5: herhaal `groupby`, `merge` en de lange vorm uit labo 4. Grafieken met plotly express vertrekken van data in de lange vorm.
- Lees bij elk labo de cursustekst naast het notebook.